

2026 年度中国青年科技创新“揭榜挂帅”擂台赛·阿里云榜题

方向 1A | 科学假设生成与研究计划设计

赛道一·科学发现 | 题目编号：XH-202619 | 依据：[阿里云赛事官网](#)

P1 | 作品信息与核心结果

参赛团队信息/成员信息（必须将盖章版本的报名表第一页和第二页截图贴上来）

【待用户补充】此处贴入盖章版报名表第一页、第二页截图（含个人信息，不入 git，提交时由用户手工插入）。

作品基本信息

挑战杯系统报名时参赛作品名称 (必填)	【待用户补充：以挑战杯系统报名名称为准】
最终参赛作品名称（如有更新可备注）	Research World：面向 125 个科学问题的科学假设生成与研究计划设计智能体系统（建议稿）
参赛选题（必填-赛道几第几个方向选题）	赛道一-方向 1A-科学假设生成与研究计划设计（题目编号 XH-202619）
参赛作品简介（300 字内）-（必填）	本作品面向科学假设生成与研究计划设计：每题由独立 Qwen 作者 Session 校正题干前提、识别缺口、核验证据、生成三个可区分方向、比较筛选并形成含 planned/executed 边界的研究计划；独立评审以六维 rubric（满分 12）与来源门逐条核验引用，findings 驱动多轮修订。已完成官方 125 题全量：候选结论 125/125，completed 8、partial 117、failed 0，2592 次调用；五深度案例最终均 12/12、来源门全过；旗舰 q049 由 V1 的 9/12 修订至 V8 的 12/12、来源 6/6。账本与哈希可回读，候选结论不等同已验证发现。
参赛作品使用 Qwen 大模型及 AI 技术说明（300 字内）-（必填）	本作品以 Qwen 系列为基座，经阿里云百炼 OpenAI 兼容端点调用：作者 Session 用 qwen3-max 完成问题理解、证据检索、三方向生成、比较筛选与研究计划；评审与回执用 gpt-5.6-sol、qwen3.7-max 等交叉执行，避免自评偏置。上下文按层拼接系统协议、canonical 原题、来源记录、历史 findings 与 planned/executed 边界；评审侧仅见固定 rubric 与被审版本，引用独立检索核验。verdict=revise 时 findings 逐条回流触发修订，形成多轮闭环；调用、token 与输出哈希均入账本可审计。

宣传视频链接/其他作品相关文件 (没有的可忽略) 链接 视频需上传至夸克网盘，分享链接复制	【待用户补充：演示视频 (≤10 分钟) 上传夸克网盘后的分享链接，制作完成后回填】
---	--

本作品核心主张

- 本作品针对的具体问题：大模型单轮回答科学问题时，易把候选解释写成已证实结论：来源不可回读、无多候选比较、研究计划空泛、planned 与 executed 混写、失败不留痕。
- 本作品实际完成的核心方法：「作者—独立评审」双角色多轮工作流：证据门槛前置、三方向候选假设、六维 rubric+来源门评审、findings 驱动修订、限定计算与 planned/executed 分离、回执复算。
- 最有代表性的结果 1（对象、口径、结果）：q049（行星轨道不坠日）：V1 9/12、来源 2/5 → V8 12/12、来源 6/6；唯一执行项 Peters 计算 $P=196.291\text{ W}$ 、 $t=1.069\text{e}23\text{ yr}$ ，评审独立复算一致。
- 最有代表性的结果 2（对象、口径、结果）：官方 125 题全量：候选结论 125/125，completed 8、partial 117、waiting_human 0、failed 0；五个深度案例最终均 12/12、来源门 6/6-9/9 全过。
- 目前仍存在的主要局限：117 题为 partial（至少一项未过轻量门槛）；未做同题重复运行；付费全文、受限数据、伦理审批与领域阈值题不可覆盖；候选结论≠已验证发现。

官网提交要求提示

- PPT/PDF 不超过 30 页；提交可调用测试 API 和可交互前端入口、代表性测试案例、详细应用技术报告和源码。
- 基座模型使用 Qwen 系列，并通过阿里云百炼或官网推荐工具调用，提供调用凭证或截图。
- 方向 A 提交智能体框架在全部 125 个科学问题上的输出结果文档；演示视频为可选，时长不超过 10 分钟。

P2 | 作品目标与实际完成内容

团队实际解决的问题

现有方法直接以单轮问答处理科学问题，存在四项不足：（1）候选解释与已证实结论不分，无来源核验；（2）单假设输出，无可区分方向间的比较与筛选；（3）研究计划空泛，planned 与 executed

混写；（4）失败、暂停与修订过程不留痕，结论无法回查。本作品针对并解决全部四项，核心目标是让每个假设具备证据闭包：可检验、可回读、可审计。

本作品实际完成的工作

已实现：（1）官方 125 题全量轻量协议运行，共 135 个 Session（125 作者+5 stopped+5 审计）、2592 次调用；（2）q049/q089/q021/q112/q098 五题深度运行：独立评审、多轮修订、回执复算、同条件直接回答对照，最终均 12/12 且来源门全过；（3）q049 限定计算（Peters 公式）真实执行并留哈希；（4）Research World 平台（web 前端、control 控制面、Agent Runtime、runner-controller 工具沙箱，docker compose 一键启动）与 T2 Playwright 5 项验收。规划中：Research Graph 与主 Agent 动态 Workflow（ADR-0037）。

总体思路




图 1 总体思路：从科学问题到候选结论的闭环（橙色为评审-修订回路）

- 本作品最终形成的主要输出：每题候选结论+研究计划+来源记录+运行账本；125 份逐题文档、5 份深度案例链（全部版本、评审、回执、对照与哈希保留）。
- 本作品已使用官方 125 道科学问题完成的实际测试：125/125 全量覆盖：135 Session、2592 次调用、非缓存输入 27,871,295 token、输出 581,255 token；completed 8、partial 117、failed 0。
- 相较直接使用大模型回答，本作品最主要的不同：双角色分离+引用逐条回读+判据可执行+失败留痕；q049 同条件直接回答对照仅 4/12 与 6/12，均无来源、无方向、无计划。

P3 | 本作品采用的科学逻辑与假设生成原则

团队实际采用的判断原则

科学判断环节	本作品实际采用的做法	采用该做法的理由
区分已有事实、文献解释与模型推断	三方向均须标注依据来源与推断边界；证据门槛要求同行评议或机构一手来源，精确主张须有可回读标识符。	防止把模型推断当文献事实；来源可回读才能支撑或否定假设。
将知识缺口转化为候选假设	从「争议/未知」清单生成机制层面可区分的三个 Direction，缺口与方向一一映射。	缺口可处理，假设才可检验；避免凭空生成。
保证候选假设可检验或可证伪	每方向含可区分预测与判定判据，判据须经独立评审验证物理正确性（如 inspiral 时间与太阳寿命比较）。	判据错误会把真实约 200 W 的耗散误判为显著，导致计划失真。
保留反对证据和替代解释	三方向并列+横向比较+评审记录被拒原因；反对证据与替代解释显式入文。	防止单主线确认偏误；被拒方向保留可复评。
避免把候选假设写成已证实结论	planned/executed 显式分离；结论限定表述（如「耗散时间远超太阳寿命，轨道不会因该机制螺旋坠日」）。	候选假设只是可提交、可回读的候选，不是新科学发现。

本作品的科学逻辑

以 q049 为例：（1）题干信息用于前提校正与知识缺口识别——「轨道衰变终将坠日」被校正为保守动力学、微弱耗散、混沌失稳与太阳演化四层机制问题；（2）同行评议一手来源用于约束假设——来源须有 DOI/arXiv 标识符且经评审逐条回读；（3）支持条件为评审 rubric 得分与来源门通过，削弱条件为引用抽查 fail 或判据无效，否定条件为复算推翻关键数值（引力波功率错 22 个数量级即被推翻重写）。

P4 | 本作品实际使用的科学资料与证据

已实际使用的来源

科学资料或证据	本作品如何获得和使用	对假设生成的具体作用	已知局限
同行评议论文与机构一手资料	anysearch 检索与提取；记录作者/年份/标题/DOI arXiv 号；评审逐条回读	承载机制主张、定量数值与判据（Peters 功率、Lyapunov 时间等）	付费墙与不可提取的 PDF 正文记为 unverifiable
官方 125 道 canonical 科学问题 (docs/questions.json)	赛事提供，作唯一输入口径	统一题目身份，输出按题入库 (q001-q125.md)	英文原题，理解存在转写噪声
运行账本 (run.md / index.md / audit-*.md)	Pi Session 自动留痕+SHA-256 内容哈希	审计 Session/调用/token/终态，支撑回执复算	raw JSONL 未全部随仓库公开（脱敏副本提交时附）
独立评审与回执记录 (review-*.md / receipt-*.md)	独立 Session 固定 rubric 评审+引用核验+账本复算	形成 revise/deliverable 判定与 findings 清单	评审范围限于声明读取的文件；非领域专家，需人工 Gate 兜底

证据处理方法

- 本作品如何判断来源是否可用：优先同行评议与机构一手来源；标识符（DOI/arXiv）必须可回读；关键数值经独立核验后方可引用。
- 遇到证据不足或相互冲突时，系统实际如何处理：记入「争议/未知」并保留两说；比较对象不等价即拒绝对照（attempt 2 只近似计算量、attempt 6 只近似长度）；错源删除或修正（q049 来源 4/5）。
- 本作品如何保留引用和科学证据之间的对应关系：主张内联标注来源编号；来源记录作者/年份/标题/DOI；评审核验结论（pass/fail+核验 URL）随评审文档入库。

科学资料可以包括论文、数据库、知识库、公开科学数据或赛事提供资料；只填写本作品实际使用的内容。

P5 | 本作品采用的评价方法

实际评价方案

实际采用的评价内容	具体评价方法	评价对象与样本	结果如何影响后续处理
六维 rubric 评分	独立评审 Session 固定 rubric：问题理解/文献证据/Direction/科学推理/研究计划/表达与追溯，各 0-2 分	五深度案例各版本 + 直接回答对照	<10 分或关键引用 fail 即 revise；达标且来源门过方可交付
来源门（引用有效率）	逐条回读 DOI/arXiv，核标识符、题名、作者与转述方向	全部显式来源（V1 分母 5 条、V8 分母 6 条）	门未过不得交付；错源删除或修正后重审
回执复算	独立 Session 重算模型、调用、token、写入与哈希	深度案例最终版	与账本不一致即拒绝（review-v15 曾被独立回执否决）
全量轻量审计	5 个独立审计 Session 各复核连续 25 题	q001-q125 全量	终态与缺口全保留，不以深度案例替代全量

评价口径说明

- 团队重点评价的是哪些方面，为什么：证据可回读与 planned/executed 边界——对照实验显示直接回答的错误集中于错引与数量级，这两项直接决定结论能否回查。
- 评价由程序、模型、团队成员或领域专家中的哪些主体完成：独立模型评审（与作者不同模型交叉）+ 程序哈希核验 + 人工 Gate（伦理/招募/阈值类题）；无领域专家常驻。
- 第一轮与第二轮是否采用同一口径；如有变化，原因是什么：同一 rubric 与来源门；变化仅在评审读取范围扩大（终审复核 v7+v8）并加入回执复算。
- 什么情况下继续生成、停止或交由研究者判断：verdict=revise 继续；deliverable + 回执一致 + 剩余项全部 planned 即停止；伦理审批、付费数据或领域阈值题交 waiting_human。

可参考相关性、证据一致性、可检验性、可证伪性、假设多样性和研究计划可执行性，但不要求全部采用。

P6 | 系统总体架构与技术闭环

本作品真实架构




图 2 系统总体架构：实线为已实现，虚线为规划中（ADR-0037）

实际模块	输入	本作品的核心处理	输出	与下一模块的关系
科学问题理解	canonical 原题+题干	前提校正；对象/范围/关键变量提取；已有认识、争议与未知三分	知识缺口清单	缺口直接决定三方向的生成空间
证据获取与组织	知识缺口+检索预算	anysearch 检索/提取；来源记录（作者/年份/标题/DOI）；支持与反对证据分列	带标识符的来源列表	约束方向取舍与研究计划判据
候选假设生成	缺口+证据	生成三个机制层面可区分 Direction+差异维度声明+横向比较	D1-D3 候选集	整体送独立评审
假设核验与筛选	D1-D3+来源	六维 rubric 打分+引用逐条回读+与直接回答基线对照	verdict+findings 清单	findings 逐条回流触发修订
研究计划与反馈修订	选定方向+findings	研究步骤/判据/planned 标注/限定计算+回执复算	最终版+研究计划+账本	计入运行账本，支撑全量审计

技术闭环的关键设计

本作品不是一次性问答：评审 findings 是显式中间结果，逐条进入下一轮作者上下文——q049 review-v1 的 5 条 findings（错配 DOI、错 arXiv 号、反向转述、22 个数量级错误、无效判据）在后续版本中逐条处置；版本链保留每轮被拒原因，回执复算防止「自己证明自己」；终态机（completed/partial/waiting_human/failed）把失败与人工暂停全部留痕。规划中的 Research Graph（ADR-0037）将把 Direction/Experiment/Claim 的证据闭包写入图谱，报告只读取有证据闭包的 Claim。

P7 | Qwen 使用方式与上下文工程

Qwen 在本作品中的实际作用

内容	本作品实际做法
使用的 Qwen 模型与调用方式	作者/基线：qwen3-max；评审/回执：gpt-5.6-sol、qwen3.7-max 等。经阿里云百炼 OpenAI 兼容端点，由 Agent Runtime 以独立 Session 调用，凭证隔离（.env 不入库）。
Qwen 承担的具体任务	作者：前提校正、缺口识别、证据检索、三方向生成、比较筛选、研究计划与候选结论；评审：rubric 打分+引用核验；回执：账本独立复算。
一次生成时提供给模型的上下文	系统协议（输出契约/证据门槛/文件边界/检索预算）、canonical 原题、来源记录、历史版本与评审 findings、planned/executed 约束（见图 3）。
结构化输出或格式约束	固定章节 Markdown 报告（研究对象/已有认识/来源记录/D1-D3/研究计划/planned 标注）；run.md frontmatter 记录终态、模型与哈希。
与检索、代码或其他工具的协作方式	web_search/extract 检索、仓库文件写入、Peters 公式脚本执行、SHA-256 计算；评审侧只读被审文档并独立检索核验。

上下文组织

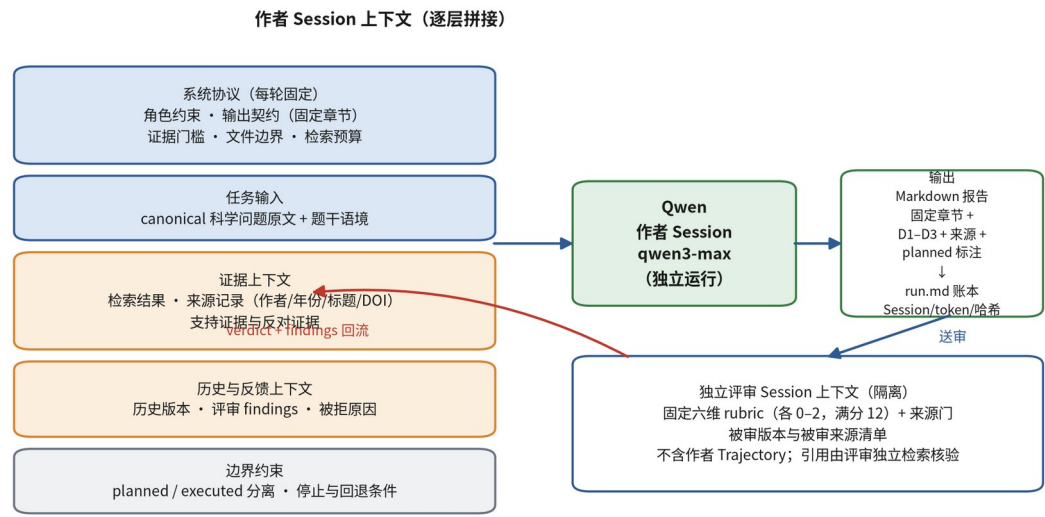


图 3 Qwen 上下文结构：作者侧分层拼接，评审侧隔离（红色为 findings 回流）

- 团队为减少无依据生成实际采取的措施：证据门槛前置声明；「未直接检索到不得引用」；来源须有可回读标识符；评审用独立检索核验而非采信作者记录。
- 上下文更新或多轮调用的触发方式：verdict=revise 即开新一轮并把 findings 逐条注入；deliverable 且回执一致即停；失败 Session 以全新 Session 重试并留痕。
- 该设计对结果带来的实际变化：q049 V1 9/12（来源 2/5）→V8 12/12（6/6）；错引、反向转述、22 个数量级错误与无效判据逐轮清零。

P8 | 科学问题理解与知识缺口识别方法

本作品实际处理过程

处理步骤	本作品实际做法	形成的中间结果	该结果如何用于假设生成
识别研究对象和范围	题干解析+前提校正	研究对象定为太阳系八大行星轨道长期稳定性；范围至太阳主序星结束	排除系外对比类内容，聚焦机制比较
提取已有条件和关键变量	从对象与机制清单提取	轨道要素 a/e/i、潮汐品质因子 Q、引力波功率、太阳质量损失率	构成计划判据与限定计算的输入
区分已有认识、争议与未知内容	检索+整理	已有：Gyr 尺度数值稳定；争议：水星失稳概率 1-2% 或更高；未知：外行星 >10 Gyr 稳定性	缺口取自争议与未知的交集

处理步骤	本作品实际做法	形成的中间结果	该结果如何用于假设生成
形成可处理的知识缺口	汇总前三步	机制时间尺度对比、混沌与耗散相对重要性、太阳质量损失影响	直接映射为三个候选方向

一项真实中间结果示例

q049 实例（V1 S1-2）：四条题干前提校正——理想牛顿力学下轨道不衰变；真实系统存在微弱耗散但时标极长；失稳主要源于混沌而非耗散；太阳演化（红巨星）是最相关的时间边界。配套变量表（a/e/i、Q、GW 功率、质量损失率）与「已有认识/争议/未知」清单，全部进入 D1-D3 的生成上下文。

P9 | 候选假设生成方法

本作品实际采用的生成机制

生成环节	本作品实际做法	该设计解决的具体问题
从知识缺口形成候选解释	每个缺口映射机制层解释：保守动力学失稳 / 微弱耗散累积 / 太阳演化边界	避免缺口悬置、假设凭空而来
生成多个可区分的候选假设	强制三个方向+显式差异维度（时间尺度/确定性/观测支持）	防止同质重复输出
将支持、反对证据纳入生成	每方向附支持依据、反对证据与不确定性	防止单边论证
控制重复、空泛或不可检验输出	差异维度+可区分预测双约束；评审对 Direction 质量单独打分	淘汰重复、空泛或不可检验输出
形成统一的候选假设表达	核心陈述/依据/反证/可检验预测/不确定性五元组+横向比较表	结构一致才能逐项评审与筛选

候选假设的实际输出内容

每条候选方向包含：核心陈述、支持依据（带来源）、反对证据或替代解释、可区分预测、不确定性五要素，并附三方向横向比较（时间尺度、确定性、观测支持）；每条声明处理结果（选为主方向/降级/不选）及理由，处理结果随版本链保留。

P10 | 候选假设核验、比较与筛选方法

本作品实际采用的处理方法

比较或核验内容	本作品如何判断	实际产生的处理结果
与科学问题是否相关	前提校正后对象/范围与原题一致	偏题方向在横向比较中剔除
与已有证据是否一致	评审逐条回读来源并与原文比对	Rasio 1996 「Earth may well not survive」 反向转述被发现并重写
是否存在冲突或错误引用	引用抽查表逐条判定 pass/fail	V1 5 条仅 2 条通过→删错配源、修正 arXiv 号→V8 6/6
是否可检验、可证伪	判据必须可执行且物理正确	「 $dE/dt < 10^{-20} \text{ W}$ 」判据被判无效→改用 Peters 公式与 inspiral 时间比较
是否与其他候选假设重复	三方向机制层面互斥检查	D1 混沌 / D2 耗散 / D3 太阳演化保持机制可区分
是否值得进入研究计划设计	主方向+补充+稀有事件分层保留	D3 选主、D2 降为补充、D1 限为稀有失稳（约 1% 概率归因已修正）

筛选结果如何形成

保留/降级/淘汰实例：D1 降级——概率归因与来源链不足；D2 不选为主——V1 把地球—太阳引力波功率误写为约 10^{-20} W （实际约 200 W）且判据无效；D3 选主但重写 Rasio 转述。全部处理结果与被拒原因随 v1-v8 与各轮 review 保留，可回放。

P11 | 研究计划生成与假设验证路径

本作品如何把假设转化为研究计划

计划环节	本作品实际生成的内容	与候选假设的关系
明确待验证的预测	耗散时标远超太阳寿命，轨道不会因该机制螺旋坠日；水星失稳为小概率稀有事件	预测直接来自 D3 主线与 D1 限定
确定所需数据、资料或实验条件	N 体积分、广义相对论修正、太阳质量损失、潮汐模型、Monte Carlo——全部标 planned	条件与假设检验手段一一对应

计划环节	本作品实际生成的内容	与候选假设的关系
形成研究步骤和分析方法	Peters 圆轨道计算 (executed : P=196.291 W、t=1.069e23 yr) →含 GR 的 N 体积分→潮汐与 MC 统计	已执行项验证计算链路，planned 项 待资源
说明不同结果分别支持或反对什么	inspiral 时间<太阳寿命→耗散主导； 否则耗散仅为长期背景、混沌决定稀 有失稳	判据双向可判定，支持或反对均明确
设置停止、回退或补充证据条件	判据无效即回退重算 (V1 判据被 Peters 替代)；计算未存 Artifact 时 以输入/哈希/复算兜底	防止无效判据误导后续实施

可执行性

- 团队如何检查研究计划是否具体、可复核：独立评审验证判据物理正确性（曾发现 22 个数量级错误）；回执复算输出与 SHA-256 一致才认定 executed。
- 研究计划中哪些内容已经具备执行条件，哪些仍是建议：executed 仅 Peters 地球—太阳计算；N 体/相对论/质量损失/潮汐/Monte Carlo 全部 planned，不冒充已执行。
- 本作品如何避免用“进一步研究”等空泛表述代替研究步骤：每步写明输入、公式/命令、产物与停止条件；无法落地者标 planned，禁止以「进一步研究」替代。

P12 | 完整运行流程与实际反馈机制

一次完整运行




图 4 完整运行流程（q049 实链）：评审 findings 触发修订，回执复算收束

本作品实际实现的反馈与失败处理

实际出现或测试过的情况	系统发现了什么问题	本作品采取的处理	对后续假设或计划的影响
错配 DOI、错误 arXiv 号、反向转述	review-v1 引用抽查 3 条 fail（有效率 2/5）	删除错配来源、修正标识符、按原文限定重写	V2 起引用 5/5；来源门此后全过
定量错误与无效判据	引力波功率错约 22 个数量级；原判据会把真实约 200 W 误判为显著	Peters 公式+完整输入+独立复算替代	V3 达 12/12；判据改为 inspiral 时间与太阳寿命比较
传输失败与人工暂停	上游 502/429 致无产物；q041-q045 人工暂停	failed 留痕+全新 Session 重试；stopped 单独记录	全量 failed=0；恢复后每题唯一候选结论

- 哪些反馈由系统自动产生：verdict 与 findings、引用抽查 pass/fail、回执复算、终态机（completed/partial/waiting_human/failed）。
- 哪些调整来自研究者或团队成员：q041-q045 暂停与恢复决定；伦理/招募/阈值类题保留 waiting_human 人工 Gate；scale-up 复审 GO/NO-GO。
- 团队实际保留了哪些前后变化，便于说明反馈是否有效：v1-v8 全版本+每轮 review+失败 Session 记录+关键文件 SHA-256；findings→修订→复评前后对照可回放。

P13 | 125 题测试方法与代表性案例选择

125 题实际测试方法

Q001-Q125 每题由一个独立 Pi 作者 Session 运行同一轻量协议：读取 canonical 问题，输出证据边界、三个可区分 Direction、横向比较、研究计划、来源与候选结论；传输失败只重试一次，停止与错误 Session 原样保留。五个独立审计 Session 各复核连续 25 题，run.md frontmatter 独占 Project 终态。共同结果均为 Qwen 候选结论与 planned 研究方案，不是已验证发现；全量结果与代价见 P19。

代表性案例为什么选择这道题

- 案例所属的科学领域及问题特点：q049 属天文学（太阳系动力学）；题干「轨道衰变终将坠日」含误导性前提，必须先校正再作答。
- 团队选择它进行完整展示的实际理由：该题覆盖错误前提校正、来源核验、三机制比较、限定计算、独立评审、修订与直接回答对照全部环节。
- 该案例能够展示本作品的哪些关键能力：错引发现与修复、22 个数量级定量纠错、planned/executed 分离、评审-修订闭环与回执复算。
- 该案例表现不能代表哪些题目或条件：需付费全文、受限数据、伦理审批、实验设施或领域阈值裁决的题目（如 q021/q112/q098 中留待人工 Gate 的部分）。

代表案例用于把方法讲透，不能代替 125 题总体结果；如另做 125 题之外的泛化测试，可在 P19 作为补充结果呈现。

P14 | 案例问题、证据基础与第一轮设置

案例的科学内容

内容	本案例的实际情况
科学问题原文	Why don't the orbits of planets decay and cause them to crash into each other? (题干断言：轨道会逐渐衰变，行星终将螺旋坠入太阳)
研究对象与关键变量	太阳系八大行星轨道长期稳定性；关键变量：半长轴 a、偏心率 e、倾角 i、潮汐品质因子 Q、引力波功率、太阳质量损失率
已有认识与主要证据	Gyr 尺度数值稳定 (Laskar 1989/2004；Batygin & Laughlin 2008)；水星 Lyapunov 时间约 5 Myr；红巨星阶段将改变内行星轨道
尚未解决的知识缺口	各机制时间尺度对比；混沌与耗散相对重要性；太阳质量损失对轨道的影响

内容	本案例的实际情况
需要保留的不确定性或争议	水星失稳概率 1-2% 或更高；外行星 >10 Gyr 超长期稳定性未知

第一轮实际生成设置

- 第一轮使用了哪些证据和约束：同行评议/机构一手来源优先；精确主张须有可回读标识符；未执行的模拟与实验一律标 planned。
- 第一轮要求系统生成什么内容：三个机制 Direction、横向比较、研究计划、来源记录与候选结论。
- 第一轮采用了哪些主要模型或方法设置：contest-qwen/qwen3-max 独立作者 Session；4 次学术搜索、2 次 DOI 提取、25 次调用、非缓存输入 98,844 token。
- 第一轮结果使用什么口径评价：独立评审六维 rubric（满分 12）+ 全部来源逐条核验（V1 分母 5 条）。

P15 | 第一轮候选假设、筛选结果与研究计划

第一轮实际生成结果

候选假设	主要依据	反对证据或替代解释	可检验预测	第一轮处理结果
H-01 · D1 N 体混沌可能导致低概率失稳	Laskar 混沌扩散；水星 Lyapunov 约 5 Myr	概率归因与来源链不完整	长期积分给出的失稳率分布	降级；概率归因与来源链需修正
H-02 · D2 潮汐、引力波等微弱耗散长期累积	潮汐理论与引力波辐射	V1 误写地球—太阳引力波功率约 10^{-20} W（实际约 200 W），判据 $dE/dt < 10^{-20}$ W 无效	轨道衰变率的直接计算/测量	不选；功率量级和计划判据错误
H-03 · D3 太阳演化先于耗散决定内行星命运	恒星演化理论；红巨星阶段轨道改变	所引 Rasio 1996 结论被反向转述	红巨星阶段内行星轨道改变的时点	选为主方向；重写转述后保留

第一轮形成的研究计划

关键步骤	实际计划内容	该步骤能够支持、反对或区分什么
1	含 GR 修正的 N 体长期积分 (planned)	区分保守稳定与混沌失稳，检验水星失稳概率
2	潮汐与引力波耗散建模 (planned)	量化各机制时标，比较是否接近太阳寿命
3	Monte Carlo 初始条件采样 (planned)	给出失稳概率区间，回答「低概率」是否成立

请保留第一轮真实结果，包括重复、证据不足、不可检验或计划不够具体的内容，不要只展示人工修订后的最佳版本。

P16 | 第一轮问题分析与调整依据

团队实际发现的问题

第一轮具体问题	判断依据	对科学结论或研究计划的影响	第二轮实际调整
关键来源不可用：Deianno/Nesvorný DOI 属另一论文	review-v1 抽查：该 DOI 实际指向 Pires et al. (Icarus 246)	D3 依据链断裂，关键论据失据	删除错配来源；Lecar arXiv 号 0111602→0111600 修正并补齐记录
关键结论反向转述：Rasio 原文「Earth may well not survive」被写成「可能幸存」	原文逐句比对	太阳演化论据方向整体反转	按原文限定重写 D3 表述
定量骨架失真：引力波功率错约 22 个数量级；判据无效	Peters 公式独立复算约 200 W	会把真实耗散误判为显著并误导计划实施	以 Peters 公式+完整输入+独立复算替代；判据改为 inspiral 时间与太阳寿命比较

调整逻辑

- 哪条证据、评价或人工意见触发了调整：review-v1 的五条独立 findings：错配 DOI、错误 arXiv 号、反向转述、22 个数量级错误、无效判据。

- 第二轮增加、删除或改变了什么：删错源、修正标识符、重写反向转述、以 Peters 公式替换判据；V2 起引用 5/5。
- 哪些内容保持不变，为什么：三方向机制框架与 planned/executed 边界不变——评审未否定框架本身，问题集中在来源与定量。
- 团队预期第二轮在哪些方面改善：引用有效率与定量骨架；实际 V2 8/12（引用 5/5），继续修订至 V3 12/12。

每项调整应对应第一轮的真实问题；如果团队没有进行某类调整，不必补写。

P17 | 第二轮候选假设、研究计划与修订结果

第一轮与第二轮的实际变化

变化内容	第一轮	第二轮	变化原因	实际结果
科学证据	5 条来源仅 2/5 有效，含错配与错号	6/6 全部可回读	逐条核验+删源修正	来源门全过
候选假设	D3 含反向转述；D2 定量错误	主线改为「保守近可积系统不自然衰变」为主、微弱耗散为补充、混沌为稀有失稳	按原文限定+复算重构	主线方向正确且论证闭合
假设比较与筛选	无有效定量判据	inspiral 时间与太阳寿命比较	Peters 独立复算	筛选判据可执行
研究计划	判据会把约 200 W 误判为显著	门槛可执行：Peters 计算 executed (P=196.291 W、t=1.069e23 yr)	完整输入+独立复算	reviewer 判 deliverable
不确定性与边界	planned/executed 未显式分离	唯一 executed=Peters 计算，其余全部 planned	边界显式标注	结论限定成立

第二轮结论

- 第二轮实际改善了什么：9/12→12/12；来源 2/5→6/6；判据物理有效；回执复算一致（review-v8 判 deliverable）。
- 哪些方面没有改善或出现了新的代价：多轮检索/修订/审核代价——q049 链 920 次调用、非缓存输入约 6.28M token；限定计算脚本未存 Artifact（以输入/公式/命令/输出/哈希/复算留痕）。

- 团队为什么在此时停止，或为什么仍需继续迭代：最终评审可交付+回执一致+剩余项全部 planned；约 1% 水星失稳概率的来源归因已修正，继续修订边际收益低。

P18 | 实际对照、消融与方案优势

团队实际完成的比较

实际比较对象	保持相同的条件	采用的评价方法	本作品结果	对照结果	结论与代价
直接回答 attempt 2 (实算近似对照)	同题、同模型 (qwen3-max)、同检索权限；各 5 次成功搜索+1 次 write	六维 rubric+引用核验	Workflow V1：9/12、来源 5 条 (2/5)、3 方向、计划有但判据错误	4/12；0 条显式来源；无 Direction、无计划	calls 少 16.00%、非缓存输入多 14.65%，但长度仅 V1 的 48.05%——只近似计算量
直接回答 attempt 6 (长度近似对照)	同上	同上	同上	6/12；0 条显式来源；经七次 Crossref curl 检索	长度 94.73%、calls 108.00%，但非缓存输入为 V1 的 11.968 倍——只近似长度
对照结论	—	—	最终版 12/12、来源 6/6	两个对照均不可直接作为学术答案	12/12 发生在独立评审、修订与限定计算之后，不能只归因于 Workflow

结果说明

- 科学逻辑方面，本作品实际改善了什么：显式来源+可执行判据+planned/executed 边界，使结论可回读、可限定、可证伪。
- 技术方法方面，本作品实际改善了什么：作者/评审分离、findings 驱动修订、回执复算，形成可审计闭环。
- 结果表现方面，本作品实际改善了什么：同条件直接回答 4/12 与 6/12、0 来源；本作品 V1 9/12→最终 12/12、来源 6/6。
- 没有改善的部分及增加的成本：全量未做同题重复运行，不声称跨采样稳健；五深度案例合计 3144 次调用、非缓存输入约 19.22M token；外部 benchmark 只证组件门，不作为科学结果。

只填写团队真实完成的对照或消融。至少提供一种同条件比较，不要求为了填表补做多组并无意义的实验。

P19 | 125 题总体结果、失败分析与适用边界

125 题实际结果

结果情况	题目数量或比例	采用的判断口径	主要表现或原因
完整形成候选假设与研究计划	8 (6.4%)	轻量门槛全过 (completed)	候选结论 125/125；含 q038/q047/q048/q053 等
部分完成或证据不足	117 (93.6%)	至少一项未过轻量门槛：来源层级/主张映射/结构/元数据/canonical 身份/planned 边界 (partial)	已有可提交、可回读结论，不等于未运行
无法处理或需研究者判断	0	waiting_human 与 failed 均为 0；5 个 stopped Session 是 q041-q045 人工暂停记录，不是 Project failed	深度案例中 3 题因伦理/设施留待人工 Gate
重复运行或稳健性表现	未开展	全量未做同题重复运行	不声称跨采样稳健性；深度案例内部多轮修订可复现




图 5 125 题结果可视化：(a) 终态分布；(b) 深度案例 rubric；(c) 全量成本（对数轴）

失败与边界

典型失败或边界问题	实际表现	原因分析	目前能够做到的程度
误导性题干前提	部分题目题干含错误前提（如 q049「坠日」）	生成时未强制前提校正会接受前提	前提校正已写入协议并在全量轻量协议中执行
错引与元数据拼接	q021 正确 PMID 拼错误 DOI；q089 DOI 有效但题名/作者错配	标识符可解析≠元数据正确	来源门逐条回读+回执复算可发现并修复

典型失败或边界问题	实际表现	原因分析	目前能够做到的程度
评审过早通过／planned 写成 executed	q112 10/12 时仍留错用标准与错误方程；review-v15 被独立回执否决	reviewer 的 deliverable 不是免检信号	分支级独立验收+人工 Gate 兜底；继续修订至全过

- 本作品未开展 125 题之外的泛化测试，故不设置该部分。
- 候选假设和研究计划仍需研究者审查，不等同于已经获得科学发现或完成真实验证。

P20 | 代码复现与提交材料

最终交付内容

交付项目	实际提交内容或入口
源码、环境、依赖与运行方法	GitHub LittleDrinks/research-world（main 分支持续维护至评审期）；cd research-world && docker compose up --build -d；服务 control:8095 / runtime:8098 / runner-controller:8096；测试：uv run pytest+web npm test
Qwen 模型、调用方式及凭证或截图	qwen3-max 经阿里云百炼 OpenAI 兼容端点；调用凭证截图【待用户补充：不泄露密钥的百炼调用凭证截图】；.env（apikey/baseurl）不入库
官方 125 题逐题输出结果文档	evidence/contest-2026/all/q001-q125.md+index.md+5 份 audit-*.md；结果站走 GitHub Pages（push 即更新）；固定存档 tag：contest-2026-submission
代表案例的输入、两轮结果和必要日志	q049：project.json、v1-v8、review-v1-v8、receipt-v10、run.md（含对照 attempt 1-7 与显示投影）；q089/q021/q112/q098 同构证据链
测试 API、示例请求与可交互前端	[DEPLOY-URL]（部署完成后回填真实可交互地址与示例请求/响应）；T2 Playwright 5 项验收（流式/刷新恢复/无内部泄露/纯文本本轮/凭证失败可见）见 web/test-results/t2/
可选演示视频	【待用户补充：≤10 分钟粗剪版，上传夸克网盘后回填链接】

提交前自检

- ☐ 技术方案 PPT/PDF 不超过 20 页，正文内容与本作品实际实现一致。
- ☐ 官方 125 道科学问题均保留逐题输出，证据不足、失败或需人工判断的题目没有被省略。
- ☐ 代表案例真实呈现第一轮结果、调整依据和第二轮变化，没有用个别案例代替总体结果。
- ☐ 源码、运行说明、Qwen 调用凭证、125 题结果文档、测试 API 和前端入口可以正常核验。
- ☐ 未将模型生成的候选假设表述为已经得到验证的科学结论；受限数据、密钥和个人信息已妥善处理。